

# Atividade prática de regressão

*Aprendizado de Máquina • Unidade 2 • Trabalho individual*

Pesquise uma aplicação de regressão, escolha um dataset no Kaggle e realize um experimento no Google Colab com regressão linear simples, regressão linear múltipla e regressão polinomial. Entregue o notebook executado e um relatório que explique suas escolhas, interprete os resultados e discuta as limitações.

## Objetivos de aprendizagem

- Relacionar uma necessidade real à previsão de um valor numérico contínuo.
- Comparar o uso de uma variável, de várias variáveis e de atributos polinomiais.
- Interpretar coeficientes, métricas e resíduos com base em evidências.
- Distinguir ajuste aos dados de treino e capacidade de generalização.

## 1 Pesquisa e escolha do dataset

Encontre no Kaggle um dataset tabular, preferencialmente em CSV, que permita usar o mesmo alvo nos três cenários. O aluno escolhe o tema; o dataset não precisa apresentar uma relação polinomial perfeita.

- O alvo deve ser numérico, ter variação e representar uma quantidade, como preço, consumo, tempo ou custo. Um código de categoria não se torna contínuo por ser um número.
- Selecione pelo menos dois preditores numéricos com significado no problema. Um deles será usado tanto na regressão simples quanto na polinomial e também deverá integrar a múltipla.
- Prefira dados com algumas centenas de registros ou mais, para permitir separação e análise. Se a base for pequena, explique o impacto sobre a confiabilidade.
- Registre título, URL do Kaggle, publicador, fonte original quando disponível, licença, data de acesso e arquivo utilizado. Identifique se os dados são reais ou sintéticos.
- Pesquise ao menos uma aplicação de regressão no tema escolhido e consulte a documentação oficial do scikit-learn. Referencie as fontes e explique a relação com seu problema.

Temas para busca: imóveis, veículos usados, consumo de energia, custos de produção e desempenho de equipamentos. Evite começar com imagens ou textos, pois exigem outra preparação.

## 2 Preparação e protocolo experimental

Use pandas, NumPy, Matplotlib e scikit-learn. Seaborn é opcional. Documente a versão das bibliotecas, a origem do arquivo e os passos para carregar os dados em uma sessão nova do Colab.

### Antes de treinar

- Defina o que representa uma linha, o alvo, sua unidade e os preditores. Exclua identificadores e informações que não estariam disponíveis no momento da previsão.
- Registre dimensões, tipos, valores ausentes, duplicatas e faixas. Justifique regras de limpeza; não exclua registros apenas para obter uma métrica melhor.
- Remova registros sem alvo e trate duplicatas exatas conforme o significado dos dados. Preserve a mesma amostra de linhas e os mesmos índices de separação nos três cenários.
- Faça a separação antes da exploração que orientará a escolha de atributos, imputação ou transformações. Use apenas o treino para essas decisões.

### Separação padrão

Para registros independentes, use aproximadamente 60% para treino, 20% para validação e 20% para teste. Primeiro reserve 20% para teste; depois separe 25% dos 80% restantes para validação. Use `train_test_split` com `random_state=42` nas duas etapas.

Treino ajusta os parâmetros. Validação orienta a escolha dos atributos e do grau. Teste fica reservado até o fechamento das escolhas. Para dados temporais, respeite a ordem; para várias linhas da mesma pessoa ou entidade, separe por grupo. Justifique qualquer adaptação.

### Pré processamento e referência de comparação

Se houver ausentes nos preditores, use `SimpleImputer` em Pipeline. Se houver padronização, ajuste `StandardScaler` somente no treino. Aplique a transformação aprendida à validação e ao teste. Não ajuste etapas com `fit` ou `fit_transform` na base inteira.

Crie um baseline com `DummyRegressor(strategy="mean")`. Ele sempre prevê a média do alvo aprendida no treino. Esse resultado será a referência para verificar se os modelos aprendem algo útil.

### Exploração no treino

Produza estatísticas descritivas, uma distribuição do alvo, um gráfico de dispersão entre o preditor principal e o alvo e uma matriz de correlação dos preditores numéricos. Registre hipóteses sobre relações lineares, curvas, valores extremos e redundância de informação.

### 3 Experimentos obrigatórios

| Cenário         | Implementação                                                             | O que investigar                                                                 |
|-----------------|---------------------------------------------------------------------------|----------------------------------------------------------------------------------|
| Linear simples  | LinearRegression com um preditor numérico                                 | Reta, intercepto, inclinação e limites da explicação.                            |
| Linear múltipla | LinearRegression com pelo menos dois preditores, incluindo o da simples   | Ganho com novas informações e interpretação condicional dos coeficientes.        |
| Polinomial      | PolynomialFeatures com include_bias=False e LinearRegression, em Pipeline | Graus 2, 3 e 5 sobre o mesmo preditor da simples; flexibilidade e generalização. |

Na polinomial, use somente o preditor da regressão simples para isolar o efeito do grau. O grau 1 corresponde à referência linear simples. A expansão muda a representação da entrada; o ajuste continua linear nos coeficientes. Ridge, Lasso e Elastic Net podem ser explorados como extensão, mas não substituem os três cenários.

#### Métricas e escolha

Calcule MAE, RMSE e  $R^2$  no treino e na validação para o baseline, a simples, a múltipla e os graus 2, 3 e 5. Use `mean_absolute_error`, `root_mean_squared_error` e `r2_score`. Se `root_mean_squared_error` não existir na versão instalada, calcule a raiz de `mean_squared_error`.

Compare os graus pelo RMSE de validação e selecione um grau. Registre também qual cenário você recomendaria, considerando validação, interpretabilidade e custo do erro. Não use o teste para escolher ou retocar modelos.

Com todas as escolhas fechadas, reajuste baseline, simples, múltipla e o grau polinomial escolhido nos dados de treino + validação. Avalie os quatro no teste uma única vez nesta etapa final. Relate resultados inesperados sem alterar as escolhas para favorecer o teste.

#### Evidências gráficas

- Dispersão com reta da regressão simples e curvas dos graus 2, 3 e 5. Use uma grade ordenada do preditor; identifique modelos, eixos, unidades e conjuntos de dados.
- RMSE de treino e validação em função do grau, incluindo o grau 1. Gere esse gráfico antes do reajuste final.
- Valores reais versus previstos para os quatro modelos finais, em subgráficos, com a linha de previsão perfeita.
- Resíduos versus valores previstos para simples, múltipla e polinomial final. Defina resíduo como valor real menos previsto e inclua a linha zero.

Não é obrigatório observar overfitting nem obter  $R^2$  alto. Uma análise correta de resultados modestos ou de um polinômio que não melhora é parte do aprendizado.

## 4 Organização e entrega

### Estrutura do notebook no Colab

- Identificação com nome, RA, turma, disciplina e título do estudo.
- Problema, pesquisa de aplicação, link do dataset e configuração das bibliotecas.
- Carregamento, inspeção inicial, regras de limpeza e separação dos conjuntos.
- Exploração do treino, hipóteses, pré-processamento e baseline.
- Experimentos simples, múltiplo e polinomial, com métricas e gráficos.
- Escolha por validação, reajuste final e avaliação no teste.
- Diagnóstico, limitações, conclusão e referências.

Intercale células de código e Markdown. Explique o papel das principais operações, especialmente fit, predict, PolynomialFeatures e Pipeline. Execute tudo do início ao fim e preserve as saídas. Não inclua senhas ou tokens no notebook.

### Itens de entrega individual

1. Notebook .ipynb criado no Google Colab, com código, explicações, gráficos e saídas. Inclua no relatório o link do Colab com permissão de leitura para o professor.
2. Relatório de análise em PDF, preenchido a partir do modelo editável fornecido. Responda às perguntas com seus resultados, cite figuras e tabelas e não reproduza apenas o código.

Nomes dos arquivos: Nome\_RA\_Unidade2\_Regressao.ipynb e Nome\_RA\_Unidade2\_Relatorio.pdf. Prazo e canal de envio serão informados pelo professor.

### O que será observado na avaliação

Adequação do problema e do dataset; pesquisa e justificativas; execução dos três cenários; separação correta e comparação justa; interpretação das métricas e dos gráficos; clareza, evidências e possibilidade de reproduzir o experimento. A qualidade da análise conta mais do que obter o maior  $R^2$ .

### Conferência antes da entrega

Verifique se o notebook executa em uma sessão nova, se o caminho do dataset está explicado, se o link abre para o professor e se os números do relatório correspondem às saídas finais. Identifique fontes de código adaptado e explique as modificações.

### Referências de apoio

LinearRegression: [https://scikit-learn.org/stable/modules/generated/sklearn.linear\\_model.LinearRegression.html](https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html)

PolynomialFeatures: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.PolynomialFeatures.html>

Métricas de regressão: [https://scikit-learn.org/stable/modules/model\\_evaluation.html#regression-metrics](https://scikit-learn.org/stable/modules/model_evaluation.html#regression-metrics)

Prevenção de vazamento de dados: [https://scikit-learn.org/stable/common\\_pitfalls.html](https://scikit-learn.org/stable/common_pitfalls.html)

DummyRegressor: <https://scikit-learn.org/stable/modules/generated/sklearn.dummy.DummyRegressor.html>