

Relatório de análise de regressão

1 Problema e pesquisa de aplicação

1. Qual quantidade você quer prever, para quem e em qual situação? Por que esse problema é de regressão?
2. Qual aplicação de regressão você encontrou na pesquisa? Descreva seu contexto, entradas, saída e utilidade. Cite a fonte.
3. Qual decisão poderia ser apoiada pela previsão? Que erro seria aceitável na unidade do alvo e qual consequência teria um erro maior? Justifique.

Análise e evidências:

1. Quero prever o consumo de combustível de um automóvel, em milhas por galão (mpg; $1 \text{ mpg} \approx 0,425 \text{ km/L}$), a partir de especificações técnicas conhecidas antes da medição: peso, potência e ano do modelo. O usuário seria um engenheiro de produto, analista de frota ou comprador, na fase inicial de projeto ou compra, antes de existir uma medição de laboratório. É regressão porque o alvo é uma quantidade contínua (ex.: 18,0; 26,5; 37,3 mpg), em que a distância entre valores importa e o erro é medido na própria unidade (mpg); não é uma classe.
2. Newman, Alimoradian e Lyons (1989) estimaram por regressão o consumo de combustível de frotas de vans e pequenos caminhões. As entradas foram cilindrada do motor, massa do veículo e velocidade média, e a saída foi o consumo. O termo de massa dominou o modelo, que explicou 77,4% (diesel) e 86,3% (gasolina) da variância. A utilidade é planejar custo e uso de combustível de uma frota. Isso se relaciona diretamente com meu problema: o mesmo raciocínio (consumo em função de massa e tamanho do motor), aqui com carros de passeio de 1970–1982. Fonte: Transportation Science, 23(1), 46–50, doi:10.1287/trsc.23.1.46. Consultei também a documentação do scikit-learn (LinearRegression, PolynomialFeatures, Pipeline, DummyRegressor, métricas de regressão e a página de armadilhas comuns/vazamento de dados).
3. A previsão apoiaria a triagem de configurações de carro (ordenar candidatos como mais econômicos ou menos econômicos) numa decisão de projeto ou de compra. Defini como erro aceitável um RMSE de até ~3 mpg, cerca de 13% do consumo médio do dataset (23,3 mpg). Um erro maior leva a classificar errado: um carro de 30 mpg previsto como 24 mpg seria descartado indevidamente. Em termos de custo, rodando 20.000 milhas por ano, um carro de 20 mpg consome 1.000 galões e um de 26 mpg consome ~769, uma diferença de ~231 galões por ano; por isso erros de vários mpg mudam a decisão.

2 Identificação e adequação do dataset

Título: Auto-mpg dataset • **Publicador:** uciml (UCI Machine Learning) • **URL do Kaggle:** <https://www.kaggle.com/datasets/uciml/autompg-dataset>

Fonte original e licença: UCI Machine Learning Repository, Auto MPG (Quinlan, 1993), revisado a partir da biblioteca StatLib (Carnegie Mellon University) — <https://archive.ics.uci.edu/dataset/9/auto+mpg>, DOI 10.24432/C5859H. Licença: CC BY 4.0 (conforme a página da UCI).

Arquivo ou versão utilizada: auto-mpg.csv (Kaggle) • Data de acesso: 05/10/2026

1. O que representa uma linha? Quantas linhas e colunas existem? Qual período, local ou população está representado?
2. O dataset é real ou sintético? Como foi coletado ou gerado? O que está documentado e o que permanece desconhecido?

3. Por que ele permite testar os três cenários? Quais limitações de representatividade podem afetar as previsões?

Análise e evidências:

1. Cada linha é um modelo/versão de automóvel. O arquivo tem 398 linhas e 9 colunas (mpg, cylinders, displacement, horsepower, weight, acceleration, model year, origin, car name), com anos de modelo de 1970 a 1982. A coluna origin codifica a região (1 = EUA: 249 carros; 2 = Europa: 70; 3 = Japão: 79), então a população é predominantemente de carros americanos da época.

2. Os dados são reais (não sintéticos). Estão documentados as variáveis, o histórico (compilação da StatLib/CMU e uso por Quinlan, 1993) e os 6 valores ausentes de horsepower, marcados com "?". Permanecem desconhecidos o procedimento de seleção dos carros, o ciclo de teste exato da medição de mpg, o tipo de combustível e de carroceria; portanto não sei se a amostra representa o mercado da época.

3. O alvo (mpg) é contínuo, há seis preditores numéricos com significado físico (um deles, weight, apresenta relação curva com o alvo, o que permite testar polinômios) e a amostra (398) é suficiente para separar treino, validação e teste, ainda que pequena (80 registros em cada conjunto de avaliação, o que torna as métricas ruidosas). Quanto à representatividade: os carros são de 1970–1982, ciclo urbano, majoritariamente americanos, e o mesmo modelo pode aparecer em anos diferentes. Por isso as previsões não devem ser extrapoladas para carros modernos ou para tipos ausentes na base (híbridos, elétricos, turbo).

3 Variáveis e exploração dos dados

Alvo e unidade: mpg : milhas por galão (maior = mais econômico) • Preditor principal da simples e da polinomial: weight : peso do carro em libras (lb)

Tabela 1. Variáveis do estudo. A regressão múltipla final usa weight, horsepower e model_year.

Variável	Papel e tipo	Unidade	Justificativa
mpg	Alvo, numérico contínuo	milhas por galão	Consumo a ser previsto; quantidade contínua com variação (10–44,3 no treino).
weight	Preditor principal (simples, polinomial e múltipla); numérico	lb	Massa exige mais energia para mover: espera-se relação decrescente com mpg ($r = -0,83$ no treino).
horsepower	Preditor da múltipla; numérico (6 ausentes no arquivo)	hp	Potência do motor; informação parcialmente redundante com o peso ($r = 0,85$).
model_year	Preditor da múltipla; numérico	ano (70 = 1970)	Tecnologia e regulação evoluem; traz informação nova ($r = 0,56$ com mpg; $r = -0,26$ com weight).
cylinders	Candidato testado, não retido; numérico discreto	nº de cilindros	Muito correlacionado com displacement ($r = 0,95$) e com weight ($r = 0,89$); não melhorou a validação.
displacement	Candidato testado, não retido; numérico	pol ³	Cilindrada; $r = 0,93$ com weight, redundante; não melhorou a validação.
acceleration	Candidato testado, não retido; numérico	s (0 a 60 mph)	Informação de desempenho; não melhorou a validação (M3).
car_name	Excluída; identificador (texto)	—	Nome do carro identifica o registro, não o descreve de forma generalizável; usada só para rotular os exemplos finais.
origin	Excluída; categoria codificada como número (1/2/3)	—	Um código de região não é uma quantidade; exigiria codificação one-hot, fora do escopo.

1. Como o alvo se distribui no treino? Há assimetria, faixas pouco representadas ou valores extremos? Apresente ao menos um gráfico.
2. O gráfico do preditor principal versus alvo sugere reta, curva ou ausência de relação clara? Que hipótese será testada?
3. Há preditores fortemente correlacionados entre si? Como essa redundância pode dificultar a interpretação dos coeficientes?
4. Todos os preditores estariam disponíveis antes de conhecer o alvo? Alguma coluna entrega a resposta direta ou indiretamente? O que foi excluído e por quê?

Análise com referência às figuras:

1. No treino (238 carros), mpg tem média 23,3, mediana 22,1, desvio-padrão 7,7, mínimo 10,0 e máximo 44,3 mpg. A distribuição tem assimetria positiva moderada (0,47): a maioria está entre ~17 e ~29 mpg e há poucos carros muito econômicos (apenas 20 dos 238 passam de 35 mpg), uma faixa pouco representada. Nenhum ponto ultrapassou as cercas de 1,5·IQR (Figura 1), então não há extremos estatísticos.




Figura 1. Distribuição de mpg (milhas por galão) no conjunto de treino: histograma (esq.) e boxplot (dir.).

2. O gráfico de weight (lb) versus mpg no treino (Figura 2) mostra relação decrescente e forte ($r = -0,83$), mas com sinal de curva convexa: a queda é íngreme até ~3500 lb e se achata nos carros pesados (~12–15 mpg); a dispersão é maior nos carros leves. Hipótese: uma reta capta a tendência principal, mas o grau 2 deve reduzir o erro sistemático nos extremos, com ganho modesto.




Figura 2. Dispersão de mpg (milhas por galão) contra weight (lb), conjunto de treino.

3. Sim. Na matriz de correlação do treino (Figura 3), weight, displacement, cylinders e horsepower são fortemente correlacionados entre si (displacement×weight = 0,93; cylinders×weight = 0,89; horsepower×weight = 0,85). Essa redundância dificulta a interpretação dos coeficientes: como as variáveis variam juntas, "mantendo as demais constantes" descreve combinações raras, os coeficientes ficam instáveis e podem dividir ou trocar o efeito entre variáveis. model_year é pouco correlacionado com weight (−0,26) e traz informação nova.




Figura 3. Matriz de correlação de Pearson (adimensional) entre os preditores numéricos e mpg, conjunto de treino.

4. Sim: todas as colunas usadas são especificações do projeto do carro (peso, potência, cilindros, cilindrada, aceleração e ano), conhecidas antes de medir o consumo, e nenhuma é derivada de mpg, então não há vazamento do alvo. Foram excluídos car_name (identificador de texto, que levaria a memorizar modelos) e origin (código de categoria, não quantidade). Dos seis preditores numéricos, três entram na múltipla final (weight, horsepower, model_year), escolhidos pela validação.

4 Qualidade e preparação

1. Quantos valores ausentes e duplicatas foram encontrados? Como foram tratados? Quantas linhas permaneceram?
2. Quais valores extremos foram mantidos ou removidos? Justifique pelo contexto, sem decidir apenas pela melhora das métricas.
3. Houve imputação, padronização ou outra transformação? Em qual conjunto seus parâmetros foram aprendidos? Como Pipeline foi usado para evitar vazamento?

Análise e evidências:

1. Foram encontrados 6 valores ausentes, todos em horsepower, codificados como "?" no arquivo (2 no treino, 3 na validação e 1 no teste). Não há duplicatas exatas nem registros sem alvo. O "?" foi convertido em NaN (parsing), e as linhas foram mantidas, pois o alvo existe e a imputação é feita depois, no Pipeline. Permaneceram 398 linhas.
2. Nenhum valor extremo foi removido. O alvo não tem pontos fora das cercas de $1,5 \cdot \text{IQR}$ no treino, e carros muito leves/econômicos (ex.: 44 mpg) ou muito pesados são casos reais da população que quero prever. Remover esses carros apenas para melhorar métricas esconderia justamente a dificuldade de previsão.

3. Houve imputação (SimpleImputer com mediana) para horsepower nos modelos que a usam: a mediana aprendida no treino foi 92,0 hp. Houve padronização (StandardScaler) apenas na polinomial, por estabilidade numérica: weight^5 chega à ordem de 10^{18} e deixaria o grau 5 mal condicionado. Ambos foram colocados dentro de um Pipeline: o fit do pipeline aprende mediana, média e desvio-padrão somente no treino e depois apenas aplica essa transformação à validação e ao teste (no reajuste final, o fit usa apenas treino + validação). Assim, nenhuma informação da validação ou do teste entra nas transformações.

5 Protocolo e funcionamento do algoritmo

Tabela 2. Tamanho dos conjuntos (total = 398 carros).

Conjunto	Registros	Finalidade
Treino	238 (59,8%)	Ajuste dos modelos e exploração
Validação	80 (20,1%)	Escolha de atributos e grau
Teste	80 (20,1%)	Avaliação final com escolhas fechadas

1. Como os conjuntos foram separados? Registre proporções, sementes e método. Por que a separação é adequada a dados independentes, temporais ou agrupados?
2. As mesmas linhas de treino, validação e teste foram usadas em todos os cenários? Como você garantiu isso?
3. Quando o teste foi acessado? Que decisões já estavam fechadas nesse momento?
4. O que fit aprende em LinearRegression e o que predict faz? Explique o critério de mínimos quadrados com suas palavras.
5. Qual a diferença entre coeficientes aprendidos e o grau escolhido pelo aluno? Por que o grau é escolhido na validação?
6. Como foi calculado o baseline? Qual média foi usada antes e depois do reajuste final? Por que a média do teste não pode orientar esse modelo?

Análise e evidências:

1. Separação aleatória em duas etapas com `train_test_split` e `random_state=42`: primeiro 20% para teste; depois 25% dos 80% restantes (= 20% do total) para validação, resultando em 60/20/20 (238/80/80). Cada linha é um carro distinto e o problema não é de previsão no tempo, então a separação aleatória é adequada a registros independentes. Ressalva: o mesmo modelo de carro pode aparecer em anos diferentes, o que reduz um pouco a independência (ver limitações).
2. Sim. A separação foi feita uma única vez, sobre as mesmas linhas limpas, e todos os cenários reutilizam esses conjuntos (mudam só as colunas: `weight` na simples e na polinomial; `weight`, `horsepower` e `model_year` na múltipla). O notebook verifica com asserts que os índices de treino, validação e teste são disjuntos.
3. O teste só foi acessado na seção 12 do notebook, depois de fechadas todas as decisões: os preditores da múltipla (M2), o grau polinomial (2) e o cenário recomendado (múltipla). Foi usado uma única vez e nenhuma escolha foi alterada depois de ver o resultado.
4. O fit de LinearRegression aprende o intercepto e os coeficientes que minimizam a soma dos quadrados dos resíduos, isto é, as diferenças entre valor real e previsto. Elevar ao quadrado evita que erros positivos e negativos se cancelem e pune mais os erros grandes. O predict não aprende nada: apenas aplica a equação já aprendida a novos dados.
5. Os coeficientes são parâmetros aprendidos pelo fit a partir dos dados de treino. O grau é uma escolha minha (hiperparâmetro) feita antes do ajuste. Se eu escolhesse o grau pelo erro de treino, sempre favoreceria o grau mais alto, pois mais flexibilidade nunca piora o ajuste no treino; por isso o grau é escolhido na validação, com dados que não participaram do ajuste.

6. O baseline (DummyRegressor, strategy="mean") prevê sempre a média de mpg do treino (23,261 mpg). Após o reajuste final, usa a média de treino + validação (23,608 mpg). A média do teste (23,143 mpg) não pode orientar o modelo: seria usar a resposta do conjunto que deve simular dados nunca vistos e tornaria a comparação injusta.

Como ler as métricas

MAE resume a magnitude média dos erros absolutos. RMSE dá mais peso a erros grandes e permanece na unidade do alvo. Menor é melhor para ambas. R^2 é uma medida relativa ao resultado de prever a média do conjunto avaliado; pode ser negativo e não é uma porcentagem de acertos.

1. Por que o RMSE de validação será usado para selecionar o grau? Que papel MAE e R^2 terão na interpretação?

2. Como um erro de uma unidade do alvo se traduz no problema real? Dê um exemplo concreto.

Análise e evidências:

1. O RMSE está na unidade do alvo (mpg) e penaliza mais os erros grandes, que são os mais custosos numa triagem de eficiência; por isso é o critério de seleção do grau na validação. O MAE dá o erro típico em mpg, de leitura direta, e o R^2 compara cada modelo ao baseline (prever a média): vale 0 para o baseline no treino e é negativo (-0,03) no baseline da validação, pois a média do treino não é a da validação. R^2 não é percentual de acertos.

2. Um erro de 1 mpg pesa mais em carros bastante beberrões: rodando 10.000 milhas, prever 25 mpg quando o real é 24 equivale a errar o consumo em ~17 galões (400 contra ~417); num carro de 12 mpg, errar para 13 mpg representa ~64 galões (833 contra ~769). Por isso o erro em mpg não tem o mesmo custo em toda a faixa.

6 Regressão linear simples e múltipla

Regressão linear simples

Preditor usado: weight (lb) • Intercepto: 45,667 mpg • Coeficiente: -0,007483 mpg por lb (-7,48 mpg a cada +1000 lb)

Expressão do modelo com os valores aprendidos (treino): $\text{mpg} = 45,667 - 0,007483 \times \text{weight}$

1. Por que esse preditor foi escolhido? Qual hipótese motivou a escolha?
2. Como interpretar a inclinação na unidade original? Se você padronizou, esclareça a escala ou reconverta o coeficiente.
3. O intercepto tem significado no domínio? Um valor zero do preditor está na faixa observada?
4. A reta captura a tendência? Onde erra mais? Use o gráfico e uma métrica para sustentar sua resposta.

Análise e evidências:

1. weight tem a correlação mais forte com mpg ($r = -0,83$) e significado físico direto (massa exige mais energia), sem ausentes. Hipótese: carros mais pesados fazem menos milhas por galão.
2. Não padronizei na simples, então o coeficiente está na unidade original: a cada +1000 lb, o consumo previsto cai 7,48 mpg, em média. É uma associação observada, não efeito causal garantido.
3. O intercepto (45,67 mpg) é o valor da reta em $\text{weight} = 0$, que está fora da faixa observada no treino (1649 a 5140 lb); portanto não tem significado físico, apenas ancora a reta.
4. Em parte. Na validação, a simples tem RMSE 4,90 mpg, MAE 3,56 mpg e R^2 0,677, contra RMSE 8,73 mpg e R^2 -0,026 do baseline (redução de ~44% no RMSE). A reta erra mais nos carros muito pesados, onde a curva real se achata e a reta passa abaixo dos pontos, e nos carros leves, onde a dispersão é grande (Figura 4, painel de validação). O erro de ~4,9 mpg está acima da tolerância de ~3 mpg definida no início.

Regressão linear múltipla

Preditores usados: weight (lb), horsepower (hp), model_year (ano) • Intercepto: -15,18 mpg (sem significado físico: ano 0 e peso 0 estão fora da faixa)

Tabela 3. Regressão múltipla (M2), ajustada no treino. Coeficientes em unidade original; efeitos padronizados em mpg por +1 desvio-padrão.

Preditor	Coeficiente	Interpretação condicional e escala
weight	-0,00616 mpg/lb	Com hp e ano fixos, +1000 lb reduz 6,16 mpg. Efeito padronizado -5,20 mpg por +1 dp; VIF 3,6.
horsepower	-0,0130 mpg/hp	Com peso e ano fixos, +100 hp reduz 1,3 mpg. Efeito padronizado -0,49 mpg por +1 dp; VIF 4,0.
model_year	+0,766 mpg/ano	Com peso e potência fixos, cada ano mais novo se associa a +0,77 mpg. Efeito padronizado +2,71 mpg por +1 dp; VIF 1,2.

1. Que informação adicional cada variável oferece? O RMSE de validação melhora em relação à simples? Cite os valores.

2. Interprete um coeficiente mantendo os demais preditores constantes. Por que essa associação não demonstra causalidade?
3. O coeficiente do preditor principal mudou entre os dois modelos? Como correlação entre preditores e variáveis omitidas podem ajudar a explicar isso?
4. Você pode comparar importância apenas pela magnitude dos coeficientes? Considere unidades, padronização e colinearidade.

Análise e evidências:

1. weight dá o tamanho/massa; horsepower dá a potência, mas é em boa parte redundante com o peso ($r = 0,85$); model_year traz informação nova (tecnologia e regulação da época). O RMSE de validação melhora de 4,90 mpg (simples) para 4,03 mpg (múltipla), com R^2 de 0,677 para 0,781. O ganho vem principalmente de model_year: weight + horsepower (M1) dá RMSE de validação 4,97, ou seja, não melhora a simples (4,90), apesar de ser melhor no treino (4,14 contra 4,30). Acrescentar acceleration (M3, 4,035) ou displacement e cylinders (M4, 4,042) também não ajudou e aumentou a colinearidade.
2. Exemplo: entre carros com o mesmo peso e a mesma potência, cada ano de modelo mais novo se associa a 0,77 mpg a mais. Isso não demonstra causalidade: model_year funciona como proxy de tecnologia e regulação da época, há variáveis omitidas (aerodinâmica, transmissão, pneus) e os dados são observacionais.
3. Sim: o coeficiente de weight passou de $-7,48$ para $-6,16$ mpg por 1000 lb (cerca de 18% menor em módulo). Na simples, weight carregava parte do efeito de horsepower e de model_year, porque carros mais pesados eram também mais potentes e mais antigos (correlação entre preditores e variáveis omitidas). Na múltipla, essa parte é atribuída a elas.
4. Não. Em unidades originais, lb, hp e anos têm escalas diferentes, então a magnitude do coeficiente não é comparável. Padronizados, weight tem o maior efeito ($-5,20$ mpg por +1 dp), depois model_year ($+2,71$) e, por último, horsepower ($-0,49$), que sozinha tem $r = -0,78$ com mpg, mas fica quase redundante depois de incluir o peso. Mesmo com VIF moderado (1,2 a 4,0), colinearidade impede ler a importância individual só pela magnitude.

7 Regressão polinomial e seleção por validação

Preditor usado: weight (o mesmo da simples) • Graus testados: 2, 3 e 5 (o grau 1 é a regressão simples)

1. O que PolynomialFeatures faz com a entrada? Mostre os atributos gerados para grau 3 e diferencie transformação e ajuste.
2. Por que o modelo é curvo em relação à entrada, mas linear nos coeficientes?
3. Como as curvas mudam com o grau? Há oscilações ou comportamento pouco plausível? Cite o gráfico.
4. Qual grau teve o menor RMSE de validação? A melhora de treino acompanhou a melhora de validação?
5. Há evidências de subajuste ou sobreajuste? Se não houver, diga isso e justifique. Grau alto, sozinho, não comprova sobreajuste.

Análise e evidências:

1. PolynomialFeatures(degree=3, include_bias=False) transforma cada valor x de weight (padronizado) em três atributos: $[x, x^2, x^3]$. Exemplo (primeiro carro do treino): weight = 2065 lb vira $x = -1,10$, $x^2 = 1,21$, $x^3 = -1,34$. Isso é transformação: não usa y e não aprende nada. O ajuste vem depois, quando LinearRegression aprende um coeficiente para cada atributo (no grau 3: -6,94, 1,11 e 0,07, com intercepto 22,12 mpg, na escala padronizada). O Pipeline encadeia StandardScaler → PolynomialFeatures → LinearRegression, de modo que tudo é aprendido só no treino.

2. O modelo é uma soma ponderada de atributos fixos: $\text{mpg} = b_0 + b_1 \cdot x + b_2 \cdot x^2 + b_3 \cdot x^3$. Em relação a x isso desenha uma curva; em relação aos coeficientes b é uma combinação linear, e por isso os mínimos quadrados continuam resolvendo um problema linear.

3. Na Figura 4, as curvas dos graus 2, 3 e 5 ficam praticamente sobrepostas na faixa com muitos dados: descem até ~3500 lb e se achatam em 12–15 mpg, ao contrário da reta, que continua caindo. Na ponta mais pesada (> 4800 lb, poucos carros), o grau 5 sobe levemente, comportamento pouco plausível (um carro mais pesado não ficaria mais econômico) e típico de polinômios de grau alto nas bordas.




Figura 4. mpg (milhas por galão) em função de weight (lb): reta (grau 1) e curvas de graus 2, 3 e 5, ajustadas no treino; pontos de treino (esq.) e de validação (dir.).

4. O grau 2 teve o menor RMSE de validação (4,742 mpg; grau 3: 4,744; grau 5: 4,765). A diferença entre os graus é de centésimos de mpg. A melhora de treino não acompanhou a de validação: o RMSE de treino foi 4,152, 4,152 e 4,144 nos graus 2, 3 e 5 (quase igual), e o de validação piorou levemente no grau 5.

5. A reta (grau 1) mostra leve subajuste: RMSE 4,30 (treino) e 4,90 (validação), pior que o grau 2 nos dois conjuntos, pois não capta a curvatura. Não há evidência clara de sobreajuste: a distância treino→validação é de ~0,6 mpg em todos os graus (0,60, 0,59, 0,59, 0,62), inclusive no baseline (7,64 → 8,73), o que indica que a validação é simplesmente mais dispersa que o treino, e não que o grau alto memorizou. Graus altos adicionam flexibilidade que não se traduz em ganho, mas isso, por si só, não comprova sobreajuste.

Resultados antes do reajuste final

Preencha a tabela com modelos ajustados apenas no treino. Use os mesmos conjuntos e unidades em todas as linhas. O grau 1 está representado pela linear simples.

Tabela 4. Métricas no treino e na validação (modelos ajustados só no treino; MAE e RMSE em mpg). A linear simples é o grau 1.

Modelo	MAE treino	RMSE treino	R² treino	MAE validação	RMSE validação	R² validação
Baseline	6,476	7,637	0,000	7,235	8,729	-0,026
Simples	3,258	4,300	0,683	3,560	4,900	0,677
Múltipla	2,573	3,329	0,810	3,045	4,031	0,781
Poli grau 2	3,061	4,152	0,704	3,365	4,742	0,697
Poli grau 3	3,061	4,152	0,704	3,370	4,744	0,697
Poli grau 5	3,052	4,144	0,706	3,396	4,765	0,694

Unidade de MAE e RMSE: milhas por galão (mpg). A Figura 5 mostra o RMSE de treino e de validação por grau (1 = reta simples); foi gerada antes do reajuste final.




Figura 5. RMSE (mpg) de treino e de validação em função do grau do polinômio em weight (1 = reta).

1. Qual grau será levado ao teste? Qual cenário você recomenda antes de abrir o teste? Registre a decisão e a evidência de validação.

2. Quando a diferença entre modelos é pequena, como interpretabilidade e complexidade influenciam sua decisão?

Decisão fechada antes do teste:

1. Grau 2 levado ao teste (menor RMSE de validação entre 2, 3 e 5: 4,742 mpg). Cenário recomendado: regressão linear múltipla (M2: weight, horsepower, model_year), com RMSE de validação 4,03 mpg, contra 4,74 do polinomial grau 2 e 4,90 da simples (Tabela 4), além de R^2 de validação de 0,78.

2. Quando a diferença é pequena, prefiro o modelo mais simples e mais interpretável: entre os graus 2, 3 e 5 (diferenças de centésimos), escolho o 2. Já entre a simples e a polinomial de grau 2, o ganho é de apenas ~3% no RMSE, o que não muda a decisão prática. A diferença da múltipla (4,03 contra 4,90) é grande, então a variável extra se justifica, e seus coeficientes seguem interpretáveis. Mesmo assim, o RMSE de validação (~4,0 mpg) ficou acima da tolerância de ~3 mpg: o modelo serve para triagem, não para especificar consumo com precisão.

8 Avaliação final e diagnóstico

Reajuste os quatro modelos abaixo em treino + validação, preservando as escolhas anteriores. Informe as métricas no teste reservado. Não transfira para esta tabela resultados do ajuste anterior.

Tabela 5. Métricas no teste ($n = 80$), modelos reajustados em treino + validação (MAE e RMSE em mpg).

Modelo final	MAE teste	RMSE teste	R ² teste
Baseline	5,955	7,347	-0,004
Linear simples	3,118	3,859	0,723
Linear múltipla	2,453	3,073	0,824
Polinomial grau 2	2,799	3,626	0,755

1. A recomendação feita na validação se sustentou no teste? Quanto cada modelo supera ou perde para o baseline? Cite números.
2. MAE e RMSE levam à mesma leitura? Se o RMSE é bem maior, quais registros com erros grandes podem explicar a diferença?
3. O gráfico de valores reais versus previstos revela alguma faixa em que há mais erro ou previsões pouco plausíveis?
4. Os resíduos das três regressões se distribuem ao redor de zero sem padrão aparente? Há curva, funil ou pontos extremos? O que cada padrão sugere?
5. Escolha dois registros de teste e apresente valor real, previsão, resíduo e uma interpretação do erro no contexto.

Diagnóstico com referência aos gráficos:

1. Sim. No teste, a múltipla teve o menor erro (RMSE 3,07; MAE 2,45; R² 0,82), seguida do polinomial grau 2 (3,63; 2,80; 0,76) e da simples (3,86; 3,12; 0,72) (Tabela 5). Todos superam o baseline (RMSE 7,35; R² $\approx$ 0): redução de RMSE de 58% (múltipla), 51% (grau 2) e 47% (simples); no MAE, de 59%, 53% e 48%. Resultado inesperado: os erros no teste foram menores que na validação (múltipla: 3,07 contra 4,03). Provável explicação: a validação era mais dispersa (RMSE do baseline 8,73 contra 7,35 no teste) e o reajuste usou 25% mais dados; com 80 registros por conjunto a variação entre amostras é grande. Não alterei nenhuma escolha por causa disso.
2. Levam à mesma ordem de modelos. A razão RMSE/MAE fica entre 1,24 e 1,30, indicando uma cauda moderada de erros grandes. Os maiores erros da múltipla são vw pickup (real 44,0, resíduo +10,0 mpg), ford granada l (-7,2 mpg) e volvo 264gl (-6,9 mpg).
3. Na Figura 6, os pontos acompanham a diagonal, mas se espalham mais nos carros com mpg real alto (> 30 mpg; 14 carros no teste), onde os modelos tendem a subestimar (resíduo médio da múltipla nessa faixa: +2,1 mpg). Nos carros pesados, os modelos lineares podem prever valores abaixo do mínimo observado no dataset (9 mpg): 2 carros do teste na simples e 3 na múltipla (ex.: previsão de 6,2 mpg para o dodge monaco (sw)), o que é pouco plausível.




Figura 6. Valores reais versus previstos de mpg (milhas por galão) no teste, para os quatro modelos finais; a linha tracejada é a previsão perfeita.

4. Na Figura 7: na simples há padrão em curva (resíduos positivos nos extremos de peso/previsão e negativos no meio), sinal de não linearidade que a reta não capta, com ponto extremo de +13,8 mpg. Na múltipla os resíduos se centram em zero (média -0,03 mpg), com leve funil (mais dispersão nas previsões altas) e ponto extremo de +10,0. No polinomial a curvatura foi atenuada, mas o funil e o ponto extremo (+13,3) permanecem: a variância do erro não é constante, ou seja, carros econômicos são mais imprevisíveis.




Figura 7. Resíduos (real - previsto, em mpg) versus mpg previsto no teste, para a simples, a múltipla e a polinomial de grau 2; a linha tracejada marca resíduo zero.

5. Ver a tabela abaixo (modelo múltipla, valores em mpg). O vw pickup é um carro leve (2130 lb), de baixa potência (52 hp) e de 1982, em faixa de eficiência onde há pouquíssimos dados; o dataset não informa combustível nem carroceria, o que pode explicar o consumo incomum. O plymouth duster é um erro típico (resíduo menor que o MAE de 2,45), em carro de peso e potência medianos.

Tabela 6. Dois registros do teste (modelo linear múltipla; valores em mpg; resíduo = real - previsto).

Registro de teste	Real	Previsto	Resíduo	Interpretação
índice 394 — vw pickup	44,0	34,0	+10,0	Muito acima da previsão: carro leve (2130 lb), baixa potência (52 hp), ano 82; faixa de eficiência com poucos dados.
índice 15 — plymouth duster	22,0	19,7	+2,3	Erro típico: peso (2833 lb) e potência (95 hp) medianos, ano 70; resíduo abaixo do MAE.

Modelo usado nos dois exemplos: Linear múltipla (weight, horsepower, model_year), reajustada em treino + validação. Unidade dos valores: mpg. Essas análises descrevem o resultado final; propostas de mudanças devem ficar como trabalho futuro.

9 Conclusões e limites de uso

1. O que você aprendeu sobre usar uma variável, adicionar variáveis e aumentar o grau? Use pelo menos um resultado numérico e um gráfico.
2. O modelo recomendado tem utilidade prática diante do erro tolerável definido no início? Justifique, mesmo se a resposta for negativa.
3. Quais limitações decorrem da amostra, qualidade dos dados, variáveis ausentes, colinearidade ou da separação adotada?
4. Em quais pessoas, locais, períodos ou faixas de valores você não confiaria na previsão? Por que extrapolar além dos valores observados pode ser arriscado?
5. Qual próximo experimento você faria e qual hipótese ele testaria? Considere mais dados, novos preditores, outra validação ou regularização sem alterar esta avaliação final.

Conclusão baseada nas evidências:

1. Só weight já reduz o RMSE de validação de 8,73 (baseline) para 4,90 mpg. Aumentar o grau trouxe pouco: o grau 2 reduziu para 4,74 e os graus 3 e 5 não melhoraram (Figura 5). Adicionar informação nova (model_year) valeu muito mais que adicionar flexibilidade: 4,03 mpg. No teste: baseline 7,35; simples 3,86; polinomial grau 2: 3,63; múltipla 3,07 mpg.
2. Em parte. Com RMSE de teste de 3,07 mpg, a múltipla fica próxima da tolerância de ~3 mpg que defini, mas na validação o erro (4,03 mpg) a ultrapassava; a conclusão depende do conjunto, o que mostra a incerteza de avaliar com 80 registros. O modelo é útil para triagem de eficiência, não para estimar o consumo exato de um carro.
3. (i) Amostra pequena (398 carros; 80 por conjunto de avaliação) e uma única separação aleatória. (ii) Dados de 1970–1982, ciclo urbano, outra era tecnológica. (iii) O mesmo modelo de carro aparece em anos diferentes, então as linhas não são totalmente independentes, o que pode favorecer um pouco as métricas. (iv) Variáveis ausentes: aerodinâmica, transmissão, tipo de combustível e de carroceria. (v) Colinearidade entre weight, horsepower e cilindrada limita a leitura individual dos coeficientes. (vi) Erro com variância não constante (funil).
4. Não confiaria em carros muito leves/econômicos (> 35 mpg, poucos dados), em carros muito pesados (previsões podem sair abaixo do mínimo observado) nem em carros modernos (híbridos, elétricos, turbo). Extrapolar além da faixa observada (1613–5140 lb; anos 1970–1982) é arriscado porque o modelo só conhece

a relação dentro dessa faixa: a reta continua caindo indefinidamente e polinômios de grau alto podem oscilar fora dela, como o grau 5 faz na ponta pesada (Figura 4).

5. Testaria modelar o consumo em galões por milha (1/mpg) ou $\log(\text{mpg})$, com a hipótese de que essa transformação linearize a relação com o peso e reduza o funil dos resíduos. Também usaria validação cruzada para estimar a incerteza das métricas, incluiria origin com codificação one-hot e testaria Ridge/Lasso contra a colinearidade, sem alterar esta avaliação final.

10 Referências e reprodução

Registre o dataset e sua fonte original, a aplicação pesquisada, a documentação consultada e fontes de código adaptado. Para cada referência, indique autor ou instituição, título, URL e data de acesso.

[1] QUINLAN, R. Auto MPG [dataset]. UCI Machine Learning Repository, 1993. DOI 10.24432/C5859H. <https://archive.ics.uci.edu/dataset/9/auto+mpg>. Licença CC BY 4.0. Acesso em 05/10/2026.

[2] UCI ML (publicador). Auto-mpg dataset. Kaggle. <https://www.kaggle.com/datasets/uciml/autompg-dataset>. Acesso em 05/10/2026.

[3] NEWMAN, P. W. G.; ALIMORADIAN, B.; LYONS, T. J. Estimating Fleet Fuel Consumption for Vans and Small Trucks. *Transportation Science*, v. 23, n. 1, p. 46–50, 1989. <https://doi.org/10.1287/trsc.23.1.46>. Acesso em 07/10/2026.

[4] scikit-learn. LinearRegression. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html. Acesso em 07/10/2026.

[5] scikit-learn. PolynomialFeatures. <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.PolynomialFeatures.html>. Acesso em 07/10/2026.

[6] scikit-learn. DummyRegressor. <https://scikit-learn.org/stable/modules/generated/sklearn.dummy.DummyRegressor.html>. Acesso em 07/10/2026.

[7] scikit-learn. Regression metrics. https://scikit-learn.org/stable/modules/model_evaluation.html#regression-metrics. Acesso em 07/10/2026.

[8] scikit-learn. Common pitfalls and recommended practices (data leakage). https://scikit-learn.org/stable/common_pitfalls.html. Acesso em 07/10/2026.

[9] Atividade prática de regressão, Aprendizado de Máquina — Unidade 2 (enunciado do professor).

1. Como o professor pode carregar o mesmo arquivo e executar o notebook em uma sessão nova? Informe passos, arquivos e versões importantes.

2. Quais trechos foram adaptados de fontes externas? Explique as adaptações e confirme que consegue explicar as operações utilizadas.

Instruções de reprodução:

1. Abrir o link do Colab acima e executar Ambiente de execução → Executar tudo em uma sessão nova. O notebook procura auto-mpg.csv na pasta atual ou em /content; se não encontrar, baixa do Kaggle com kagglehub (dataset público uciml/autompg-dataset, sem token) e, em último caso, pede o upload do arquivo baixado em <https://www.kaggle.com/datasets/uciml/autompg-dataset>. O arquivo usado é auto-mpg.csv (398 linhas, 9 colunas). Versões registradas na seção 2 do notebook: Python 3.12.3, NumPy 2.4.4, pandas 3.0.2, Matplotlib 3.10.8, scikit-learn 1.8.0. A semente é 42 em todas as etapas aleatórias; nenhuma senha ou token é usado.

2. A estrutura geral (Pipeline, train_test_split, métricas e DummyRegressor) segue os exemplos da documentação do scikit-learn, listados nas referências; o restante foi escrito para este estudo. O cálculo do VIF foi implementado manualmente (regressão de cada preditor sobre os demais). A única adaptação relevante ao padrão da documentação é o StandardScaler antes do PolynomialFeatures, justificado por estabilidade numérica. Consigo explicar todas as operações utilizadas, em especial fit, predict, PolynomialFeatures e Pipeline.

Conferência final

Todos os cenários foram executados? As tabelas distinguem validação e teste? Os valores correspondem ao notebook? Toda conclusão tem evidência? Os gráficos têm legenda e unidades? O link do Colab permite leitura? O relatório foi exportado em PDF?

Resposta: sim para os cenários, tabelas separadas (4 e 5), valores do notebook e gráficos com legenda e unidades. Pendente: nome, RA, turma e link do Colab (leitura).